

**I. Zastosowanie algorytmu optymalizacji do rozwiązania problemu testowego (0-6 pkt.)**

1. Wybrać dowolną funkcję ze strony [https://en.wikipedia.org/wiki/Test\\_functions\\_for\\_optimization](https://en.wikipedia.org/wiki/Test_functions_for_optimization) (sekcja Test functions for single-objective optimization). Podać jej nazwę i wzór.
2. Wykonać rysunek trójwymiarowy oraz poziomicowy funkcji dla podanego zakresu zmiennych  $x$  oraz  $y$ .
3. Wybrać dwa algorytmy optymalizacji heurystycznej, np. algorytm roju (ang. Particle Swarm Optimization, PSO) lub algorytm szarego wilka (ang. Grey Wolf Optimization, GWO). Algorytm zaimplementować w dowolnym języku, np. MATLAB, Python lub C. Można wykorzystać dostępne implementacje algorytmów, np. dostępne na stronie <http://www.mathworks.com/matlabcentral/fileexchange> lub <https://github.com>. Bardzo dobry przyborek oferujący implementację algorytmu PSO można pobrać ze strony <http://www.mathworks.com/matlabcentral/fileexchange/25986>.
4. Wyznaczyć minimum (minima) globalne funkcji. Obliczenia powtórzyć wielokrotnie, przyjmując różne wartości parametrów algorytmu optymalizacji oraz wartości początkowe obliczanych parametrów.
5. Zaprezentować i omówić otrzymane wyniki, w szczególności wpływ rodzaju algorytmu optymalizacji, parametrów algorytmu oraz punktu początkowego na otrzymane wyniki, liczbę iteracji oraz czas obliczeń.

**Proces**

Regulowany proces (symulowana rzeczywistość) opisany jest następującymi równaniami (jak w projekcie nr 2)

$$\begin{aligned}x_1(k) &= -\alpha_1 x_1(k-1) + x_2(k-1) + \beta_1 g_1(u(k-5)) \\x_2(k) &= -\alpha_2 x_1(k-1) + \beta_2 g_1(u(k-5)) \\y(k) &= g_2(x_1(k))\end{aligned}$$

gdzie  $u$  – sygnał wejściowy,  $y$  – sygnał wyjściowy,  $x_1, x_2$  – zmienne stanu,  $\alpha_1 = -1,272717$ ,  $\alpha_2 = 0,332871$ ,  $\beta_1 = 0,028400$ ,  $\beta_2 = 0,019723$  oraz

$$g_1(u(k-5)) = \frac{(\exp(5,25u(k-5)) - 1)}{(\exp(5,25u(k-5)) + 1)}, \quad g_2(x_1(k)) = 0,8(1 - \exp(-2x_1(k)))$$

W nominalnym punkcie pracy  $u = y = x_1 = x_2 = 0$ , sygnał wejściowy może się zmieniać w granicach od  $u^{\min} = -1$  do  $u^{\max} = 1$ .

**II. Strojenie nieliniowego algorytmu regulacji predykcyjnej (0-4 pkt.)**

1. Zastosować wybrany algorytm optymalizacji heurystycznej do optymalizacji wartości parametrów algorytmu regulacji predykcyjnej typu NPL (czyli horyzontów  $N$ ,  $N_u$  i współczynnika  $\lambda$ ) powyższego procesu. Zastosować trajektorię wartości zadanej w postaci kilku skoków o różnej amplitudzie (jak w projekcie nr 2). Minimalizowana funkcja celu uwzględnia sumę kwadratów różnic między trajektorią zadaną  $y^{\text{zad}}(k)$  a rzeczywistym wyjściem procesu (symulowanego)  $y(k)$  dla wszystkich dyskretnych chwil czasu  $k$

$$E = \sum_{k=k_{\text{pocz}}}^{k_{\text{konc}}} (y^{\text{zad}}(k) - y(k))^2$$

2. Obliczenia powtórzyć wielokrotnie, przyjmując różne wartości parametrów algorytmu optymalizacji oraz wartości początkowe obliczanych parametrów. Zaprezentować i omówić otrzymane wyniki (wpływ parametrów na wartość funkcji celu oraz jakość regulacji).
3. Dla wybranych wartości parametrów zamieścić przebiegi sygnału wejściowego i wyjściowego procesu. Skomentować otrzymane wyniki.

### III. Modelowanie neuronowe procesu (zadanie dodatkowe, punktowane dodatkowo w skali 0-3 pkt.)

1. Przeprowadzić uczenie modelu neuronowego drugiego rzędu

$$\hat{y}(k) = f(u(k - \tau), u(k - \tau - 1), \hat{y}(k - 1), \hat{y}(k - 2))$$

powyższego procesu za pomocą wybranego algorytmu optymalizacji. Zastosować perceptronową sieć neuronową o jednej warstwie ukrytej z funkcją aktywacji tangensa hiperbolicznego. Przyjąć zestawy danych, wartość opóźnienia  $\tau$  oraz liczbę neuronów ukrytych takie same, jak w projekcie nr 2. Model uczyć w trybie rekurencyjnym (predyktor OE). Uczenie powtórzyć co najmniej 20 razy, odpowiednio dobrać liczbę iteracji algorytmu, licznosc populacji i inne parametry algorytmu. **Uwaga: uczenie może wymagać bardzo dużej liczby iteracji.**

2. Wybrać dwa modele neuronowe: najgorszy spośród testowanych oraz najlepszy (pod względem błędu weryfikacji). Modele zasymulować w trybie rekurencyjnym (predyktor OE) dla zbioru danych uczących i weryfikujących.
3. Podać błędy wybranych modeli dla zbioru danych uczących i weryfikujących.
4. Zamieścić przebiegi sygnału wyjściowego procesu i wybranych modeli oraz wykresy korelacji tych sygnałów (dla zbioru weryfikującego).

#### Uwaga:

- a) Umieścić sprawozdanie w pliku pdf oraz **spakowane** wszystkie pliki źródłowe (MATLAB) w systemie Studia (moduł Sprawozdania) do dnia 27.1.2025, godz. 23.59. Nie przysyłać innych plików, np. graficznych, doc, tex.
- b) Maksymalna liczba punktów wynosi 10 (+3 punkty dodatkowe). Za każdy rozpoczęty dzień spóźnienia odejmowany jest 1 punkt.
- c) Projekt będzie przyjmowany do dnia 29.1.2024, godz. 23.59.